### FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

### Seminar

# Statisticko testiranje

Mentor:

Student: Neven Miculinić Prof. dr. sc. Bojana Dalbelo-Bašić Dr. sc. Goran Glavaš

May 2015

# Contents

Co	ontents	1			
1	$\mathbf{U}\mathbf{vod}$	1			
2	Hipoteza	2			
	2.1 Null hipoteza	2			
	2.2 Altrenativna hipoteza	3			
	2.3 Primjeri	3			
3	Odluke Odluke	4			
Bi	Bibliography				

## Chapter 1

## Uvod

Ovaj seminar se bavi statistickim testovima, tj. provjeravanjem ili pobijanjem hipoteza. Pocetna premisa je jednostavna, imamo neku hipotezu koju zelimo provjeriti. Ona moze biti svakojaka:

- na FERu je 99% muskaraca
- dnevno 1000 studenata FFZG idu u Cassandru
- $\bullet\,$  Varianca bodova na SISu je 15

Kao sto vidimo u primjerima one testiraju vjerojatnost za neki paramater u populaciji  $\Theta$ . On moze biti svakojak kao sto vidimo u primjerima: postotak pripadnika jedne subpopulacije u populaciji, broj, varijanca neke statistike i mnoge druge oblike.

Na temelju uzorka iz populacije donosimo zakljucke. Buduci da sami uzorci podlijezu sansi (npr. nas uzorak FERovaca sastoji se od 20 zena no prezentira li to sliku populacije?) zelimo znati koliko su sigurne nase pretpostavke.

# Chapter 2

# Hipoteza

Sto sve moze biti hipoteza. U uvodu smo vidjeli neke primjere, dok cu se ovdje baviti s dvaja pojma:

- Null hipoteza (eng. Null hypothesis)  $H_0$
- $\bullet$  Altrenativna hipoteza (eng. Altrenative hypothesis)  $H_a$

#### 2.1 Null hipoteza

Null hipoteza je nasa osnova pretpostavka o parametru populacije. Ona kao takva podlijeze statistici uzorka te populaciju. Zasto uzorka? Evo jedan primjer. Zelimo provjeriti hipotezu iz uvoda *na FERu je 99% muskaraca*. Nerealno je i skupo ici od svakog pojedinca na fakultetu, provjeriti s kojeg je on faksa te zapravo analizirati svakog pripadnika populacije.

Time se bavi deskriptivna statstika, dok statisticka testiranja ulaze u inferencijsku statistiku.

Zato radimo uzorak od n primjeraka iz populacije i na temelju njih zakljcujemo za cijelu populaciju. Naravno zanima nas kolika je greska toga naseg suda.

Hipoteza

### 2.2 Altrenativna hipoteza

No sto ako nasa hipoteza nije tocna? Onda vrijedi altrentivna hipoteza. Evo dat cu primjer.

Neka je  $H_0$ : Varianca bodova na SISu je 15. tj.  $H_0$ :  $\Theta = 15$ . Sto bi bila altrenativna hipoteza?

Logicno negacija  $H_0$  te je time  $H_a: \Theta \neq 15$ . Ovo je dvostrana altrenativna hipoteza jer parametar  $\Theta$  u altrenative moze biti i veci i manji od nulla.

Postoji jos jedana mogucnost altrenativne hipoteze, a to je jednostrana. Glasi ovako:  $H_a: \Theta > 15$  ili  $H_a: \Theta < 15$ . Kao sto vidimo ova altrenativna hipoteza gleda samo jednu stranu toga parametra te se zato zove jednostavna.

Kada rabimo koju? Ako iz uzorka dobijemo  $\hat{\Theta}=16$ logicnije je uzeti jednostranu koja kaze $H_a:~\Theta>15$ 

Najcesce uzimamo dvostranu altrenativnu hipotezu osim ukoliko nam nije bitno... la la.

Sada kada malo razmislim, nije mi bas najjasnije tocno kada korstimo jednostranu altrenativu, a kada dvostranu

3

### 2.3 Primjeri

Imamo tvornicu igracaka i bitno nam je da su igracke u projeku vece od 15 cm. Tj.  $\mu > 15cm$ . Proizvodni proces je nastiman tako da prosjek bude 16 cm s nepoznatom varijancom. Naravno, samo zato jer je proces tako nastima, to ne znaci da se on u stvarnosti tako i ponasa. Stoga je ovdje prirodno uzeti  $H_0: \mu = 16cm$  te  $H_a: \mu < 16cm$  buduci da nam je dulje od 15 cm nego da je tocan prosjek.

## Chapter 3

# Odluke Odluke

E sada kada smo prezentirali hipoteze trebamo se za jednu odluciti te odrediti koliko smo sigurni u nasu pretpostavku. Imamo 4 moguca ishoda:

		Null hypothesis is	
		True	False
		Type I error	
Presuda testa je:	Odbaci	False Positive	Tocno
r resuda testa je:		Sansa je significance level $\alpha$	
			Type II error
	Prihvati (Fail to accept)	Tocno	$\beta$
			False Negative

Kakav god test odabrali da potvrdimo ili odbacimo  $H_0$  on moze rezultirati u Type I ili Type II greskama. Evo jednog ilustrativnog primjera za Type I gresku.

Situacija je sljedeca. Vi ste cuvar nekoga sela i vasa je duznost oglasiti uzbunu ukoliko se vuk priblizava. Time je  $H_0$  vuka nema. E ukoliko vuka stvarno nema, a vi ste oglasili uzbunu vi ste nacinili Type I pogresku ilitiga False positive.

Slicnu scenarij mozete vidjeti i s testom za trudnocu. Ukoliko krecete od hipoteze  $H_0$ : Nema trudnoce te  $H_a$ : trudnoca te stvarno niste trudni, ali test pokazuje trudnocu to je jos jedan primjer Type I greske. Ona se oznacava s grckim slovom  $\alpha$  te se naziva nivo znacajnost testa (eng. significance level).

Hipoteza

Pri samoj konstrukcji statistickog testa ukoliko je  $H_0$  tocna mozemo lijepo ustimati  $\alpha$  na prihvatljivu granicu te ga mozemo lijepo ustimati jer cesto pretpostavljamo kako funkcija razdiobe izgleda.

No dobro, ovo je sve super, mozemo nastimati test da nam je  $\alpha \approx 0$  no sto time dobivamo? Tu u pricu ulaze Type II greske koje imaju vjerojatnost  $\beta$ . Ona se događa kada je  $H_0$  netocno, no test neuspijeje pobiti  $H_0$  nego presudi tocnosti null hipoteze.

Koristeci primjere iz prethodne sekcije, vas test presudi da vuka nema dok on stvarno dolazi pred vasa vrata. Također vi ste trudni dok test za trudnocu to ne pokazuje dok nije prekasno. Faktor  $\beta$  je povezan s pojmom snaga testa (eng. power) koja iznosti  $1-\beta$ . Ona je definirana kao vjerojatnost da ce test odbiti  $H_0$  kada je ona lazna.

No taj faktor  $\beta$  je cesto nemoguce odrediti bez nekih pretpostavki. Npr. ((ovdje ubaciti neku normalnu distribuciju i koliko je beta ako je  $\mu + \delta$  te kako on ovisi. Malo matematike i formulu upisati))

Kod svakog statistickog testa dolazimo do balansacije snage i znacajnosti istoga. Sto je veca snaga testa to je veca znacajnost i obratno. Idealni test bi imao snagu 1 te znacajnost 0, no to u praksi nije moguce, te time treba pazljivo balansirati ta dva parametra tjekom izrade samoga testa.

Ovdje dodati jos par slika i lijepse pojasniti

Kod svih ovih testova koliko mi pretpostavljamo o funkciji razdiobe? Da li i u altrenativi pretpostavljamo normalnu npr. samo s drugim parametrima ili kako?

Koliko se parametri slucajne varijable mijenjaju kod linearnih transformacija? Konkretno pdf,  $\mu$ ,  $\sigma$  i  $\sigma^2$ . Koliko sam skuzio isto linearno osim varijance koja se kvadratno mijenja

# **Bibliography**

- [1] N. F. Hubele D. C. Montgomery, G. C. Runger. *Engineering statistics*. London: John Wiley & Sons, Inc., 2001.
- [2] V. A. Clark O. J. Dunn. Applied statistics: analysis of variance and regression. London: John Wiley & Sons, Inc., 1974.
- [3] Željko Pauše. Uvod u matematičku statistiku. Školska knjiga, 1993.
- [4] Neven Elezović. Diskretna vjerojatnost. Element, Zagreb, 2007.
- [5] Neven Elezović. Slučajne variable. Element, Zagreb, 2007.
- [6] Neven Elezović. Matematička statistika i stohastički procesi. Element, Zagreb, 2007.